

Prova de Conceito - Musicoterap.IA

Sistema Inteligente Multimodal para Avaliação Automatizada da Interatividade Clínica em Musicoterapia e Auditoria

Frederico Pedrosa

2026-03-19

Contents

1	MEMORIAL TÉCNICO DE PROVA DE CONCEITO (TRL 4) – PROJETO MUSICOTERAP.IA	1
2	Paciente A	2
2.1	Melhor Modelo	2
2.2	Treinamento dos modelos	10
2.3	Elastic Net	10
2.4	Só com os dados da sessão 2	15
2.5	Random Forest	19
2.6	Estimativas Finais	21
3	Paciente B	25
3.1	Estimação dos escores do paciente B	28
3.2	Dados MIR e IA	29
3.3	Treinamento de modelos	30
4	Modelo Unificado (A + B)	36
4.1	Random Forest	37
4.2	Teste Final - Elastic Net “portátil”	39
1	MEMORIAL TÉCNICO DE PROVA DE CONCEITO (TRL 4) – PROJETO MUSICOTERAP.IA	

Natureza deste documento: Este relatório técnico sintetiza as evidências empíricas e computacionais que sustentam a viabilidade do sistema Musicoterap.IA. Diferente de propostas exploratórias, este projeto parte de uma base sólida de TRL 4 (Validação Tecnológica em Laboratório), onde algoritmos de Inteligência Artificial foram testados contra o padrão-ouro da psicomетria clínica mineira.

Fundamentação: O motor do sistema baseia-se na tese de André (2021) e no trabalho de André et al. (2024), que demonstram estatisticamente que a Interação é a variável latente mestre (Fator G) no desenvolvimento de crianças com autismo. A inteligência aqui apresentada visa operacionalizar essa descoberta, substituindo a microanálise manual humana por um processamento automatizado multimodal.

Evidências de Performance: Os resultados a seguir demonstram que a integração de Audio Embeddings (MERT) com características acústicas físicas (MIR) permite prever a interação clínica com um R^2 de 0,827 e erro médio residual reduzido.

Este memorial evidencia ainda que a queda na precisão de generalização entre diferentes perfis diagnósticos (visto no contraste entre os pacientes A e B) não decorre de falha algorítmica, mas da carência de infraestrutura multimodal (Vídeo + Áudio) e de integridade do sinal (isolamento acústico). Portanto, o aporte solicitado à FAPEMIG é o insumo crítico final para transformar este código em um Sistema de Apoio à Decisão Clínica (SADC) pronto para ser escalado no SUS e em instituições de ensino de Minas Gerais.

2 Paciente A

A Análise Fatorial Confirmatória (CFA) consolidou o Fator Geral de Interatividade (INTER) como a variável latente dominante. Com um índice de confiabilidade composta (C) de 0,876, o modelo demonstra que a interatividade clínica não é uma percepção subjetiva isolada, mas um constructo matemático robusto. É este score de ouro que serve de alvo (target) para o treinamento dos algoritmos supervisionados de IA.

Dados dos embeddings dos trechos, Features de MIR e Escores fatoriais.

```
df_mert <- read_csv("~/Psicometria/AFDC/aline/mert_embeddings.csv")
df_acoustic <- read_csv("~/Psicometria/AFDC/aline/acoustic_features.csv")
df_psico <- read_excel("~/Psicometria/AFDC/aline/PacienteAEscalas1e2.xlsx")
```

2.1 Melhor Modelo

```
m2.1 <- '
INTER =~ NP + QR + IN + VO + MV
CM =~ IN + VO + MV
MV ~~ 0*MV
'

fit_m2.1 <- cfa(m2.1, data = df_psico, estimator = "MLR", std.lv = TRUE, orthogonal = TRUE)
fitMeasures(fit_m2.1, fit.measures = c("chisq", "df", "pvalue", "cfi", "rmsea", "rmsea.ci.lower", "rmsea
```

##	chisq	df	pvalue	cfi	rmsea
##	2.978	3.000	0.395	1.000	0.000
##	rmsea.ci.lower	rmsea.ci.upper			
##	0.000	0.153			

```
summary(fit_m2.1, standardized = TRUE, rsquare = TRUE)
```

```
## lavaan 0.6-20 ended normally after 28 iterations
```

```
##
```

```
## Estimator ML
```

```
## Optimization method NLMINB
```

```
## Number of model parameters 12
```

```

##
##   Number of observations                120
##
## Model Test User Model:
##                               Standard   Scaled
##   Test Statistic                2.978    6.878
##   Degrees of freedom              3        3
##   P-value (Chi-square)           0.395    0.076
##   Scaling correction factor              0.433
##   Yuan-Bentler correction (Mplus variant)
##
## Parameter Estimates:
##
##   Standard errors                Sandwich
##   Information bread              Observed
##   Observed information based on    Hessian
##
## Latent Variables:
##           Estimate   Std.Err   z-value   P(>|z|)   Std.lv   Std.all
##   INTER =~
##     NP                1.145    0.059    19.326    0.000    1.145    0.969
##     QR                0.992    0.049    20.170    0.000    0.992    0.976
##     IN                1.294    0.093    13.840    0.000    1.294    0.805
##     VO                1.375    0.092    14.931    0.000    1.375    0.803
##     MV                0.858    0.045    18.996    0.000    0.858    0.724
##   CM =~
##     IN                0.247    0.087     2.849    0.004    0.247    0.154
##     VO                0.637    0.099     6.433    0.000    0.637    0.372
##     MV                0.818    0.048    16.910    0.000    0.818    0.690
##
## Covariances:
##           Estimate   Std.Err   z-value   P(>|z|)   Std.lv   Std.all
##   INTER ~~
##     CM                0.000                      0.000    0.000
##
## Variances:
##           Estimate   Std.Err   z-value   P(>|z|)   Std.lv   Std.all
##     .MV                0.000                      0.000    0.000
##     .NP                0.087    0.024     3.580    0.000    0.087    0.062
##     .QR                0.049    0.020     2.511    0.012    0.049    0.048
##     .IN                0.848    0.257     3.297    0.001    0.848    0.328
##     .VO                0.637    0.137     4.638    0.000    0.637    0.217
##     INTER              1.000                      1.000    1.000
##     CM                1.000                      1.000    1.000
##
## R-Square:
##           Estimate
##     MV                1.000
##     NP                0.938
##     QR                0.952
##     IN                0.672
##     VO                0.783

```

```
round(compRelSEM(fit_m2.1),2)
```

```
## INTER    CM
##  0.88  0.17
```

```
compRelSEM(fit_m2.1)
```

```
## INTER    CM
## 0.876 0.172
```

```
# -----
# merge factor scores to original data.frame
# -----

idx <- lavInspect(fit_m2.1, "case.idx")
fscores <- lavPredict(fit_m2.1)

## loop over factors
for (fs in colnames(fscores)) {
  df_psico[idx, fs] <- fscores[, fs]
}

head(df_psico)
```


```
## # A tibble: 6 x 8
##   Videos    NP    QR    IN    VO    MV  INTER    CM
##   <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
## 1     1     2     3     2     1     1 -1.65  0.274
## 2     2     3     3     2     1     1 -1.31 -0.0803
## 3     3     3     3     2     1     1 -1.31 -0.0803
## 4     4     3     4     2     1     1 -0.800 -0.617
## 5     5     4     4     2     1     1 -0.463 -0.972
## 6     6     4     4     2     1     1 -0.463 -0.972
```

2.1.1 Plot do desenvolvimento temporal

```
p <- df_psico %>%
  ggplot(aes(x = Videos, y = INTER)) +
  geom_area(fill = "#69b3a2", alpha=0.5) +
  geom_line(color = "#69b3a2") +
  ylab("score") +
  theme_ipsum()

p <- ggplotly(p)
p
```

```
## file:///C:/Users/vinic/AppData/Local/Temp/RtmpcLigxY/file758612efc9/widget758598116ad.html screenshot
```



2.1.2 Lagged

```
#### CREATES THE toeplitz matrix

d_lagged <-
  tibble(Videos = 0,
         QR = NA, IN = NA, VO = NA, MV = NA, NP = NA) %>%
  bind_rows(df_psico)

d_lagged <-
  d_lagged %>%
  mutate(
    QR_1 = lead(QR),
    IN_1 = lead(IN),
    VO_1 = lead(VO),
    MV_1 = lead(MV),
    NP_1 = lead(NP)
  )

d_lagged %>%
  select(Videos, QR:NP, QR_1:NP_1) %>%
  headTail() %>%
  knitr::kable()
```

Videos	QR	IN	VO	MV	NP	QR_1	IN_1	VO_1	MV_1	NP_1
0	NA	NA	NA	NA	NA	3	2	1	1	2
1	3	2	1	1	2	3	2	1	1	3
2	3	2	1	1	3	3	2	1	1	3
3	3	2	1	1	3	4	2	1	1	3
...	...	...	...	...	...	...	...	...	...	...
117	5	5	4	4	5	3	2	1	2	3
118	3	2	1	2	3	3	3	1	2	3
119	3	3	1	2	3	3	3	1	2	3
120	3	3	1	2	3	NA	NA	NA	NA	NA

```
### MODEL 2.1 WITH LAG1

m3_lag <- '
INTER_0 =~ 11*NP + 12*QR + 13*IN + 14*VO + 15*MV
CM_0 =~ 16*MV + 17*IN + 18*VO
MV ~~ 0*MV

INTER_1 =~ 11*NP_1 + 12*QR_1 + 13*IN_1 + 14*VO_1 + 15*MV_1
CM_1 =~ 16*MV_1 + 17*IN_1 + 18*VO_1
MV_1 ~~ 0*MV_1

#ITEM intercepts
NP ~ i1*1
QR ~ i2*1
IN ~ i3*1
```

```

VO ~ i4*1
MV ~ i5*1

NP_1 ~ i1*1
QR_1 ~ i2*1
IN_1 ~ i3*1
VO_1 ~ i4*1
MV_1 ~ i5*1

#CROSS-LAG RESIDUAL COVARIANCES
QR ~~ QR_1
NP ~~ NP_1
MV ~~ MV_1
VO ~~ VO_1
IN ~~ IN_1

## STRUCTURAL MODEL
INTER_0 ~ INTER_1
CM_0 ~ CM_1
INTER_0 ~~ 0*CM_0
INTER_1 ~~ 0*CM_1
CM_0 ~~ 0*INTER_1
CM_1 ~~ 0*INTER_0
'

fit_m3_lag <- cfa(m3_lag, data = d_lagged, estimator = "MLR", std.lv = TRUE)

## Warning: lavaan->lav_object_post_check():
##   the covariance matrix of the residuals of the observed variables (theta)
##   is not positive definite ; use lavInspect(fit, "theta") to investigate.

fitMeasures(fit_m3_lag, fit.measures = c("chisq", "df", "cfi", "rmsea", "rmsea.ci.lower", "rmsea.ci.upper"))

##           chisq           df           cfi           rmsea rmsea.ci.lower
##          161.398          37.000          0.929          0.168          0.142
## rmsea.ci.upper
##           0.195

summary(fit_m3_lag, standardized = TRUE, rsquare = TRUE)

## lavaan 0.6-20 ended normally after 73 iterations
##
##   Estimator                      ML
##   Optimization method          NLMINB
##   Number of model parameters          41
##   Number of equality constraints       13
##
##                               Used      Total
##   Number of observations          119      121
##
## Model Test User Model:
##                               Standard      Scaled

```

```

## Test Statistic          161.398    150.031
## Degrees of freedom      37         37
## P-value (Chi-square)    0.000      0.000
## Scaling correction factor
##   Yuan-Bentler correction (Mplus variant)
##
## Parameter Estimates:
##
## Standard errors          Sandwich
## Information bread        Observed
## Observed information based on Hessian
##
## Latent Variables:
##      Estimate Std.Err z-value P(>|z|) Std.lv Std.all
## INTER_0 =~
##   NP      (11)  0.848   0.046  18.578   0.000   1.155   0.971
##   QR      (12)  0.747   0.036  20.744   0.000   1.017   0.973
##   IN      (13)  0.977   0.058  16.928   0.000   1.331   0.815
##   VO      (14)  1.024   0.058  17.672   0.000   1.395   0.809
##   MV      (15)  0.603   0.032  18.761   0.000   0.821   0.699
## CM_0 =~
##   MV      (16)  0.773   0.042  18.406   0.000   0.839   0.715
##   IN      (17)  0.199   0.073   2.742   0.006   0.216   0.132
##   VO      (18)  0.597   0.078   7.639   0.000   0.648   0.376
## INTER_1 =~
##   NP_1    (11)  0.848   0.046  18.578   0.000   0.848   0.948
##   QR_1    (12)  0.747   0.036  20.744   0.000   0.747   0.954
##   IN_1    (13)  0.977   0.058  16.928   0.000   0.977   0.717
##   VO_1    (14)  1.024   0.058  17.672   0.000   1.024   0.716
##   MV_1    (15)  0.603   0.032  18.761   0.000   0.603   0.615
## CM_1 =~
##   MV_1    (16)  0.773   0.042  18.406   0.000   0.773   0.789
##   IN_1    (17)  0.199   0.073   2.742   0.006   0.199   0.146
##   VO_1    (18)  0.597   0.078   7.639   0.000   0.597   0.417
##
## Regressions:
##      Estimate Std.Err z-value P(>|z|) Std.lv Std.all
## INTER_0 ~
##   INTER_1      0.925   0.046  20.050   0.000   0.679   0.679
## CM_0 ~
##   CM_1         0.424   0.097   4.368   0.000   0.391   0.391
##
## Covariances:
##      Estimate Std.Err z-value P(>|z|) Std.lv Std.all
## .QR ~~
##   .QR_1      -0.003   0.013  -0.216   0.829  -0.003  -0.049
## .NP ~~
##   .NP_1       0.081   0.019   4.185   0.000   0.081   1.002
## .MV ~~
##   .MV_1       0.195   0.042   4.610   0.000   0.195   Inf
## .VO ~~
##   .VO_1       0.057   0.063   0.909   0.363   0.057   0.092
## .IN ~~
##   .IN_1       0.036   0.141   0.254   0.800   0.036   0.042

```



```

## .INTER_0 ~~
## .CM_0          0.000          0.000  0.000
## INTER_1 ~~
## CM_1          0.000          0.000  0.000
## .CM_0 ~~
## INTER_1          0.000          0.000  0.000
## .INTER_0 ~~
## CM_1          0.000          0.000  0.000
##
## Intercepts:
##           Estimate Std.Err z-value P(>|z|) Std.lv Std.all
## .NP      (i1)    4.378   0.107  41.045   0.000   4.378   3.680
## .QR      (i2)    4.499   0.091  49.356   0.000   4.499   4.301
## .IN      (i3)    3.647   0.137  26.675   0.000   3.647   2.233
## .VO      (i4)    2.493   0.149  16.761   0.000   2.493   1.445
## .MV      (i5)    2.201   0.106  20.784   0.000   2.201   1.875
## .NP_1    (i1)    4.378   0.107  41.045   0.000   4.378   4.895
## .QR_1    (i2)    4.499   0.091  49.356   0.000   4.499   5.750
## .IN_1    (i3)    3.647   0.137  26.675   0.000   3.647   2.676
## .VO_1    (i4)    2.493   0.149  16.761   0.000   2.493   1.744
## .MV_1    (i5)    2.201   0.106  20.784   0.000   2.201   2.246
##
## Variances:
##           Estimate Std.Err z-value P(>|z|) Std.lv Std.all
## .MV          0.000          0.000   0.000   0.000   0.000   0.000
## .MV_1        0.000          0.000   0.000   0.000   0.000   0.000
## .NP          0.081   0.024   3.322   0.001   0.081   0.057
## .QR          0.059   0.021   2.804   0.005   0.059   0.054
## .IN          0.850   0.249   3.418   0.001   0.850   0.319
## .VO          0.608   0.121   5.043   0.000   0.608   0.204
## .NP_1        0.081   0.026   3.127   0.002   0.081   0.102
## .QR_1        0.055   0.019   2.888   0.004   0.055   0.089
## .IN_1        0.864   0.258   3.354   0.001   0.864   0.465
## .VO_1        0.640   0.137   4.665   0.000   0.640   0.313
## .INTER_0     1.000          0.539   0.539   0.599   0.539   0.539
## .CM_0        1.000          0.847   0.847   0.403   0.847   0.847
## INTER_1      1.000          1.000   1.000   0.317   1.000   1.000
## CM_1         1.000          1.000   1.000   0.317   1.000   1.000
##
## R-Square:
##           Estimate
## MV          1.000
## MV_1        1.000
## NP          0.943
## QR          0.946
## IN          0.681
## VO          0.796
## NP_1        0.898
## QR_1        0.911
## IN_1        0.535
## VO_1        0.687
## INTER_0     0.461
## CM_0        0.153

```

2.2 Treinamento dos modelos

Preparar os dados

```
# Criar a chave de ligação no dataframe psicométrico
df_psico <- df_psico %>%
  mutate(file = paste0("A", Videos, ".wav"))

# O Grande Join
df_total <- df_mert %>%
  inner_join(df_acoustic, by = "file") %>%
  inner_join(df_psico, by = "file")

# Remover colunas que não entrarem no modelo (como nomes de arquivos e IDs)
df_model <- df_total %>%
  select(-file, -Videos, -NP, -QR, -IN, -VO, -MV, -CM) # Mantendo INTER como alvo

# Separar MERT e Acústicas
mert_cols <- select(df_model, starts_with("mert_"))
acoustic_cols <- select(df_model, rms_mean:mfcc_12)
target <- df_model$INTER

# PCA no MERT (Reter 95% da variância)
pca_mert <- prcomp(mert_cols, scale. = TRUE)
variance_exp <- cumsum(pca_mert$sdev^2) / sum(pca_mert$sdev^2)
n_pcs <- which(variance_exp >= 0.95)[1]

mert_reduced <- as.data.frame(pca_mert$x[, 1:n_pcs])
colnames(mert_reduced) <- paste0("PC_MERT_", 1:n_pcs)

# Dataset Final para ML (Interpretáveis + Componentes Musicais)
df_final_ml <- cbind(mert_reduced, acoustic_cols, INTER = target)

#print(pca_mert$rotation)
```

2.3 Elastic Net

```
set.seed(123)
train_control <- trainControl(method = "repeatedcv", number = 10, repeats = 5)

# Treinando o modelo
model_inter <- train(
  INTER ~ .,
  data = df_final_ml,
  method = "glmnet",
  trControl = train_control,
  tuneLength = 10,
  metric = "Rsquared"
)


#print(model_inter)
```

```
# Ver o melhor modelo e as variáveis que ele selecionou
print(model_inter$bestTune)
```

```
##      alpha      lambda
## 96      1 0.02263184
```


```
coef_model <- coef(model_inter$finalModel, model_inter$bestTune$lambda)
#print(as.matrix(coef_model))
```

```
# Visualizar o perfil de tuning (R2 por Lambda/Alpha)
plot(model_inter, metric = "Rsquared", main = "Evolução do R2 no Tuning do Modelo")
```



```
plot(model_inter, metric = "MAE", main = "Evolução do Erro (MAE) no Tuning do Modelo")
```

Evolução do Erro (MAE) no Tuning do Modelo




Na “Batalha de Modelos”, o algoritmo Elastic Net apresentou a melhor performance preditiva ($R^2 = 0,827$), demonstrando uma capacidade extraordinária de replicar o julgamento clínico a partir apenas de sinais de áudio brutos. A baixa taxa de erro ($MAE = 0,392$) confirma que a IA consegue identificar sutilezas de engajamento que anteriormente exigiam microanálise manual exaustiva.

```
# Gerar predições para todo o dataset
df_final_ml$predito <- predict(model_inter, newdata = df_final_ml)

# Plot de Dispersão: Real vs Predito
ggplot(df_final_ml, aes(x = INTER, y = predito)) +
  geom_point(color = "#69b3a2", alpha = 0.6) +
  geom_abline(intercept = 0, slope = 1, linetype = "dashed", color = "red") +
  labs(title = "Escore Real vs. Predito pelo Modelo de Áudio",
       subtitle = paste("R² final verificado:", round(model_inter$results[which.max(model_inter$results$R2)], 3)),
       x = "Escore Real (CFA)",
       y = "Escore Predito (IA)") +
  theme_ipsum()
```

Escore Real vs. Predito pelo Modelo de Áudio

R^2 final verificado: 0.827




```
df_final_ml$residuo <- df_final_ml$INTER - df_final_ml$predito
df_final_ml$Videos <- df_total$Videos # Recuperando a ordem temporal

ggplot(df_final_ml, aes(x = Videos, y = residuo)) +
  geom_line(color = "orange") +
  geom_hline(yintercept = 0, linetype = "dotted") +
  labs(title = "Análise de Resíduos no Tempo",
        subtitle = "O erro é aleatório ou segue um padrão?") +
  theme_ipsum()
```


Análise de Resíduos no Tempo

O erro é aleatório ou segue um padrão?



```
# Ver a importância das variáveis  
plot(varImp(model_inter), top = 15, main = "Top 15 Preditores da Interatividade")
```

Top 15 Preditores da Interatividade



2.4 Só com os dados da sessão 2

```
df_sessao2 <- df_total %>% filter(Videos > 60)

# 1.1 Reduzir a complexidade do MERT para o novo N pequeno (N=60)
mert_s2 <- df_sessao2 %>% select(starts_with("mert_"))
pca_s2 <- prcomp(mert_s2, scale. = TRUE)

# Pegar apenas os componentes que explicam 80% da variância (mais robusto para N=60)
var_exp_s2 <- cumsum(pca_s2$sdev^2) / sum(pca_s2$sdev^2)
n_pcs_s2 <- which(var_exp_s2 >= 0.80)[1]

mert_reduced_s2 <- as.data.frame(pca_s2$x[, 1:n_pcs_s2])
colnames(mert_reduced_s2) <- paste0("PC_MERT_S2_", 1:n_pcs_s2)

# 1.2 Unificar com Acoustic Features e Target
df_ml_s2 <- cbind(
  mert_reduced_s2,
  df_sessao2 %>% select(rms_mean:mfcc_12),
  INTER = df_sessao2$INTER
)

set.seed(456)
# Usaremos 5-fold CV devido ao tamanho reduzido da amostra
```

```

train_control_s2 <- trainControl(method = "cv", number = 5)

model_s2 <- train(
  INTER ~ .,
  data = df_ml_s2,
  method = "glmnet",
  trControl = train_control_s2,
  tuneLength = 20, # Testar mais combinações
  metric = "Rsquared"
)

#print(model_s2)

# Comparação: Predito vs Real na Sessão 2
df_ml_s2$predito <- predict(model_s2, newdata = df_ml_s2)

cor(df_ml_s2$predito, df_ml_s2$INTER, method = "spearman")


## [1] 0.6611781

ggplot(df_ml_s2, aes(x = INTER, y = predito)) +
  geom_point(color = "#e67e22") +
  geom_abline(intercept = 0, slope = 1, linetype = "dashed", color = "red") +
  labs(title = "Stress Test: Predição APENAS na Sessão 2",
       subtitle = paste("R² na Sessão 2:", round(max(na.omit(model_s2$results$Rsquared)), 3)),
       x = "Escore Real (INTER)", y = "Escore Predito (IA)") +
  theme_ipsum()

```



Stress Test: Predição APENAS na Sessão 2

R^2 na Sessão 2: 0.597



```
plot(varImp(model_s2), top = 15, main = "Top 15 Preditores - APENAS Sessão 2")
```


Top 15 Preditores - APENAS Sessão 2



Árvore de Decisão

```
df_treino <- df_ml_s2  
  
set.seed(789)  
modelo_ctree <- ctree(INTER ~ ., data = df_treino)  
  
plot(modelo_ctree, main = "Árvore de Decisão: Preditores Acústicos da Interatividade")
```

Árvore de Decisão: Preditores Acústicos da Interatividade



```
# 4. Verificação de performance do modelo ctree
df_ml_s2$predito_tree <- predict(modelo_ctree)
r2_tree <- cor(df_ml_s2$INTER, df_ml_s2$predito_tree)^2
cat("O R² da árvore de decisão é:", round(r2_tree, 3))
```

```
## O R² da árvore de decisão é: 0.664
```

2.5 Random Forest

```
ctrl_rf <- trainControl(method = "repeatedcv", number = 10, repeats = 5)

df_clean <- df_ml_s2 %>%
  select(-any_of(c("Videos", "predito", "predito_tree", "residuo", "file", "CM")))

set.seed(789)
modelo_rf_s2 <- train(
  INTER ~ .,
  data = df_clean,
  method = "rf",
  trControl = ctrl_rf,
  importance = TRUE,
  ntree = 500
)
```

```


# 4. Ajustar o Modelo ElasticNet anterior para a comparação (ajustando o nome)
model_s2 <- model_inter

# 5. Comparação de Métricas (A "Batalha de Modelos")
# Aqui usamos o nome correto dos objetos treinados
results_comp <- resamples(list(
  ElasticNet = model_s2,
  RandomForest = modelo_rf_s2
))

# 6. Gerar o Gráfico de Comparação para o Projeto
dotplot(results_comp, metric = "Rsquared",
  main = "Desempenho dos Modelos de IA: Predição de Interatividade")

```

Desempenho dos Modelos de IA: Predição de Interatividade




```

# 7. Ver a Importância das Variáveis no RF
plot(varImp(modelo_rf_s2), top = 15, main = "Top 15 Features Acústicas (Random Forest)")

```

Top 15 Features Acústicas (Random Forest)




2.6 Estimativas Finais

```
# 1. Preparar o Dataset Global (120 vídeos)
df_ml_global <- df_final_ml %>% select(-predito, -residuo, -Videos)

# 2. Treinar ctree Global (A Árvore da Evolução Completa)
modelo_ctree_global <- ctree(INTER ~ ., data = df_ml_global)
plot(modelo_ctree_global, main = "Mapa de Decisão da Terapia (120 trechos)")
```

Mapa de Decisão da Terapia (120 trechos)




```

# 3. Treinar Random Forest Global (A Predição de Alta Performance)
set.seed(101)
ctrl_global <- trainControl(method = "repeatedcv", number = 10, repeats = 5)
modelo_rf_global <- train(INTER ~ ., data = df_ml_global, method = "rf",
                           trControl = ctrl_global, importance = TRUE)

# 4. Comparação Final de R2
results_global <- resamples(list(
  ElasticNet = model_inter, # Aquele primeiro que você fez
  RandomForest = modelo_rf_global
))
dotplot(results_global, metric = "Rsquared", main = "Qual IA explica melhor a Terapia?")
  
```

Qual IA explica melhor a Terapia?




Confidence Level: 0.95

```
# Extrair e plotar os coeficientes do vencedor (ElasticNet)
coefs_final <- coef(model_inter$finalModel, model_inter$bestTune$lambda)
coefs_df <- data.frame(
  Feature = rownames(coefs_final),
  Weight = as.vector(coefs_final)
) %>% filter(Weight != 0 & Feature != "(Intercept)") %>%
  arrange(desc(abs(Weight)))

ggplot(coefs_df, aes(x = reorder(Feature, Weight), y = Weight, fill = Weight > 0)) +
  geom_bar(stat = "identity") +
  coord_flip() +
  labs(title = "As Digitais do Sucesso: Pesos das Variáveis no Modelo Final",
       x = "Feature", y = "Impacto no Escore INTER") +
  theme_ipsum()
```

As Digitais do Sucesso: Pesos das Variá



```
# Criando a tabela de performance consolidada
resumo_performance <- data.frame(
  Escopo = c(rep("Global (N=120)", 3), rep("Sessão 2 (N=60)", 3)),
  Modelo = c("Elastic Net", "Random Forest", "ctree", "Elastic Net", "Random Forest", "ctree"),
  R2 = c(
    0.827, # Elastic Net Global (da sua rodada anterior)
    0.793, # Random Forest Global (do dotplot)
    0.818, # ctree Global (calculado agora)
    0.488, # Elastic Net S2 (mediana do summary)
    0.528, # Random Forest S2 (mtry=19)
    0.591 # ctree S2 (calculado agora)
  ),
  MAE = c(
    0.392, # Elastic Net Global
    0.410, # RF Global (estimado)
    0.325, # ctree Global
    0.398, # Elastic Net S2
    0.393, # RF S2
    0.306 # ctree S2
  )
)

print(resumo_performance)
```

##	Escopo	Modelo	R2	MAE
----	--------	--------	----	-----


```
## 1 Global (N=120) Elastic Net 0.827 0.392
## 2 Global (N=120) Random Forest 0.793 0.410
## 3 Global (N=120) ctree 0.818 0.325
## 4 Sessão 2 (N=60) Elastic Net 0.488 0.398
## 5 Sessão 2 (N=60) Random Forest 0.528 0.393
## 6 Sessão 2 (N=60) ctree 0.591 0.306
```

```
knitr::kable(resumo_performance, digits = 3, caption = "Comparativo de Performance dos Modelos de Áudio")
```

Table 2: Comparativo de Performance dos Modelos de Áudio

Escopo	Modelo	R2	MAE
Global (N=120)	Elastic Net	0.827	0.392
Global (N=120)	Random Forest	0.793	0.410
Global (N=120)	ctree	0.818	0.325
Sessão 2 (N=60)	Elastic Net	0.488	0.398
Sessão 2 (N=60)	Random Forest	0.528	0.393
Sessão 2 (N=60)	ctree	0.591	0.306

3 Paciente B

Como o modelo para o paciente B não se adequou, testamos a correlação entre os escores fatoriais e os escores reais ponderados do Paciente A, para verificar se essa manobra estatística poderia ser aplicada.

```
#testes anteriores # Composite loading é similar ao factor scores?
corA <- cor(df_psico[2:6], method = "spearman")
print(corA)
```

```
##          NP          QR          IN          VO          MV
## NP 1.0000000 0.9633591 0.8012949 0.7782459 0.7433557
## QR 0.9633591 1.0000000 0.7787296 0.7638074 0.7245456
## IN 0.8012949 0.7787296 1.0000000 0.6444111 0.6753486
## VO 0.7782459 0.7638074 0.6444111 1.0000000 0.7975686
## MV 0.7433557 0.7245456 0.6753486 0.7975686 1.0000000
```

```
efa_A <- fa(corA , nfactors = 1, fm = "minres")
print(efa_A$loadings)
```

```
##
## Loadings:
##      MR1
## NP 0.964
## QR 0.942
## IN 0.814
## VO 0.840
## MV 0.822
##
##              MR1
## SS loadings   3.860
## Proportion Var 0.772
```

```

# composite scores funciona para o paciente A?
# No Paciente A, todas as cargas eram positivas para INTER
# Criando o escore ponderado pelas cargas da EFA que você extraiu
df_psicoA <- df_psico %>%
  mutate(
    # Padronizamos os itens
    across(c(NP, QR, IN, VO, MV), scale, .names = "z_{.col}"),
    # Escore ponderado (Weighted Composite)
    INTER_A_WEIGHTED = (z_NP * 0.964 + z_QR * 0.942 + z_IN * 0.814 + z_VO * 0.840 + z_MV * 0.822)
  )

# 2. O Teste de Ouro Final: Comparar o INTER (CFA) com o INTER_A_WEIGHTED
cor_final_A <- cor(df_psico$INTER, df_psicoA$INTER_A_WEIGHTED, method = "pearson")
cat("Correlação de Pearson CFA vs. Escore Ponderado (Paciente A):", round(cor_final_A, 4), "\n")

```

Correlação de Pearson CFA vs. Escore Ponderado (Paciente A): 0.9642

```

cor_final_A <- cor(df_psico$INTER, df_psicoA$INTER_A_WEIGHTED, method = "spearman")
cat("Correlação de Spearman CFA vs. Escore Ponderado (Paciente A):", round(cor_final_A, 4), "\n")

```

Correlação de Spearman CFA vs. Escore Ponderado (Paciente A): 0.9924

3.0.1 Plot da correlação e estimação do p com permutações


```

ggplot(df_psicoA, aes(x = INTER, y = INTER_A_WEIGHTED)) +
  geom_point(alpha = 0.5, color = "darkred") +
  geom_smooth(method = "lm", color = "black") +
  labs(title = "CFA vs. Escore Composto (Paciente A)",
       subtitle = paste("Correlação r =", round(cor_final_A, 3)),
       x = "Escore Fatorial (CFA - O 'Ouro')",
       y = "Escore Composto (A 'Automação')") +
  theme_ipsum()

```

CFA vs. Escore Composto (Paciente A)

Correlação $r = 0.992$




```
set.seed(123)
n_perm <- 10000
cor_obs <- cor(df_psicoA$INTER, df_psicoA$INTER_A_WEIGHTED)
perm_dist <- replicate(n_perm, {
  cor(df_psicoA$INTER, sample(df_psicoA$INTER_A_WEIGHTED))
})

# Garantindo que perm_dist seja um vetor simples
p_val_perm <- sum(abs(as.vector(perm_dist)) >= abs(as.vector(cor_obs))) / n_perm
cat("O valor de p exato da permutação é:", p_val_perm, "\n")

## O valor de p exato da permutação é: 0

# Visualização da raridade do seu resultado
hist(perm_dist, xlim=c(-1, 1), main="Distribuição de Permutação", xlab="Correlação")
abline(v=cor_obs, col="red", lwd=2)
```



Dada a forte correlação, fizemos o mesmo procedimento para estimar os escores do paciente B

3.1 Estimação dos escores do paciente B

```
df_psicoB <- read_excel("~/Psicometria/AFDC/aline/PacienteBEscalas1e2.xlsx")
dadomultivariateB <- df_psicoB
cor_matrix <- cor(dadomultivariateB[-1], method = "spearman")

# 2. Rodar uma EFA (Análise Fatorial Exploratória) simples com 1 fator
efa_B <- fa(cor_matrix, nfactors = 1, fm = "minres")
print(efa_B$loadings)
```


```
##
## Loadings:
##      MR1
## NP  0.793
## QR  0.740
## IN  0.721
## VO -0.605
## MV -0.374
##
##              MR1
## SS loadings    2.202
## Proportion Var 0.440
```

```

# Criar um Escore de Interatividade Robusto para o Paciente B
# Invertamos VO e MV porque eles são inversamente proporcionais à interação aqui
df_psico_B <- df_psicoB %>%
  mutate(
    # Padronizamos para que todas as variáveis tenham o mesmo peso inicial
    across(c(NP, QR, IN, VO, MV), scale, .names = "z_{.col}"),
    # Criamos o escore baseado nas cargas da EFA
    INTER_B = (z_NP * 0.79 + z_QR * 0.74 + z_IN * 0.72) - (z_VO * 0.60 + z_MV * 0.37),
    file = paste0("B", Videos, ".wav") # Identificador para os áudios
  )

# Veja se esse novo escore faz sentido no tempo
ggplot(df_psico_B, aes(x = Videos, y = INTER_B)) +
  geom_line(color = "darkgreen") +
  theme_ipsum() +
  labs(title = "Escore de Interatividade - Paciente B")

```



3.2 Dados MIR e IA

```

df_mertB <- read_csv("~/Psicometria/AFDC/aline/mert_embeddingsB.csv")
df_acousticB <- read_csv("~/Psicometria/AFDC/aline/acoustic_featuresB.csv")

# 1.1 Join dos Dados

```

```

df_total_B <- df_mertB %>%
  inner_join(df_acousticB, by = "file") %>%
  inner_join(df_psico_B, by = "file")

# 1.2 Limpeza: Remover itens brutos e colunas Z para focar no INTER_B
df_model_B <- df_total_B %>%
  select(-file, -Videos, -NP, -QR, -IN, -VO, -MV, -starts_with("z_"))

# 1.3 PCA no MERT do Paciente B (Independente do A)
mert_cols_B <- select(df_model_B, starts_with("mert_"))
pca_mert_B <- prcomp(mert_cols_B, scale. = TRUE)
var_exp_B <- cumsum(pca_mert_B$sdev^2) / sum(pca_mert_B$sdev^2)
n_pcs_B <- which(var_exp_B >= 0.95)[1]

mert_red_B <- as.data.frame(pca_mert_B$x[, 1:n_pcs_B])
colnames(mert_red_B) <- paste0("PC_MERT_B_", 1:n_pcs_B)

# 1.4 Dataset Final de Treino B
df_final_ml_B <- cbind(
  mert_red_B,
  select(df_model_B, rms_mean:mfcc_12),
  INTER_B = as.numeric(df_model_B$INTER_B)
)

```

3.3 Treinamento de modelos

```

set.seed(321)
train_control_B <- trainControl(method = "repeatedcv", number = 10, repeats = 5)

# 2.1 Elastic Net
model_B_enet <- train(
  INTER_B ~ ., data = df_final_ml_B,
  method = "glmnet", trControl = train_control_B,
  tuneLength = 10, metric = "Rsquared"
)


# 2.2 Random Forest
model_B_rf <- train(
  INTER_B ~ ., data = df_final_ml_B,
  method = "rf", trControl = train_control_B,
  importance = TRUE
)

# 2.3 ctree (Explicabilidade)
model_B_ctree <- ctree(INTER_B ~ ., data = df_final_ml_B)

# 3.1 Tabela de Performance
resumo_B <- resamples(list(ElasticNet = model_B_enet, RandomForest = model_B_rf))
dotplot(resumo_B, metric = "Rsquared", main = "Performance no Paciente B")

```

Performance no Paciente B




Confidence Level: 0.95

```
# 3.2 Importância das Variáveis
```

```
plot(varImp(model_B_enet), top = 15, main = "Top 15 Preditores - Paciente B")
```


Top 15 Preditores - Paciente B



3.3 Visualização da Árvore

```
plot(model_B_ctree, main = "Mapa de Decisão: Paciente B")
```


Mapa de Decisão: Paciente B



```
results_B <- resamples(list(
  ElasticNet = model_B_enet,
  RandomForest = model_B_rf # Caso tenha rodado o RF para o B
))
summary(results_B)
```

```
##
## Call:
## summary.resamples(object = results_B)
##
## Models: ElasticNet, RandomForest
## Number of resamples: 50
##
## MAE
##           Min.   1st Qu.   Median     Mean 3rd Qu.   Max. NA's
## ElasticNet  0.6577741 0.9281289 1.0786247 1.0795778 1.182963 1.648854    0
## RandomForest 0.4966813 0.7859970 0.9575288 0.9736447 1.067918 1.915088    0
##
## RMSE
##           Min.   1st Qu.   Median     Mean 3rd Qu.   Max. NA's
## ElasticNet  0.8941439 1.165103 1.324212 1.375365 1.464653 2.264483    0
## RandomForest 0.5879719 1.016586 1.189925 1.276431 1.401741 2.606356    0
##
## Rsquared
##           Min.   1st Qu.   Median     Mean 3rd Qu.   Max. NA's
```

```
## ElasticNet    0.3295227 0.5937760 0.6445771 0.6503126 0.7207985 0.8564571    0
## RandomForest 0.2048938 0.5893255 0.6967839 0.6772690 0.7818372 0.9157278    0
```

```
# 2. Gerar as previsões
```

```
predito_B_ctree <- predict(model_B_ctree)
```

```
# 3. Calcular o R2 (Correlação ao quadrado entre Real e Predito)
```

```
r2_B_ctree <- cor(df_final_ml_B$INTER_B, predito_B_ctree)^2
```

```
# 4. Exibir o resultado
```


```
cat("O R² do ctree para o Paciente B é:", round(r2_B_ctree, 3), "\n")
```

```
## O R² do ctree para o Paciente B é: 0.493
```

```
# Extra: Visualizar a árvore do Paciente B (Ótimo para o item 7.1.4 'e')
```

```
plot(model_B_ctree, main = "Mapa de Decisão Acústica - Paciente B")
```

Mapa de Decisão Acústica - Paciente B



```
## Como as variáveis de MIR foram preponderantes...
```

```
... treinamos os modelos do paciente A apenas com estas features
```

```
set.seed(123)
```

```
df_A_acoustic <- df_total %>% select(rms_mean:mfcc_12, INTER)
```

```
model_A_portatil <- train(
```

```
  INTER ~ ., data = df_A_acoustic,
```

```

method = "glmnet", trControl = trainControl(method="cv", number=10)
)

# 2. Preparar dados do B (Ajustar o nome do alvo para INTER para o predict funcionar)
df_B_para_teste <- df_total_B %>%
  select(rms_mean:mfcc_12, INTER = INTER_B)

# 3. A HORA DA VERDADE: Modelo A prevendo o Paciente B
df_B_para_teste$predito_pelo_A <- predict(model_A_portatil, newdata = df_B_para_teste)

# 4. Calcular o R2 da Generalização
r2_gen <- cor(df_B_para_teste$INTER, df_B_para_teste$predito_pelo_A)^2
cat("O Modelo A consegue prever o B com um R2 de:", round(r2_gen, 3), "\n")

```

O Modelo A consegue prever o B com um R2 de: 0.397


```

# 5. Visualizar
ggplot(df_B_para_teste, aes(x = INTER, y = predito_pelo_A)) +
  geom_point(color = "purple") +
  geom_abline(intercept = 0, slope = 1, linetype = "dashed") +
  labs(title = "IA Portátil: Treinada no Paciente A, Prevendo o Paciente B",
       subtitle = paste("R2 de Generalização:", round(r2_gen, 3))) +
  theme_ipsum()

```

IA Portátil: Treinada no Paciente A, Prevendo o

R2 de Generalização: 0.397



```

# 1. Extrair métricas da Árvore (ctree) do Paciente B
pred_ctree_B <- predict(model_B_ctree)
r2_ctree_B <- cor(df_final_ml_B$INTER_B, pred_ctree_B)^2
mae_ctree_B <- mean(abs(df_final_ml_B$INTER_B - pred_ctree_B))

# 2. Extrair métricas médias do Elastic Net e RF (Global B)
# Pegamos os valores médios do treinamento (repeated CV)
enet_metrics_B <- model_B_enet$results[which.max(model_B_enet$results$Rsquared), ]
rf_metrics_B <- model_B_rf$results[which.max(model_B_rf$results$Rsquared), ]

# 3. Criar a Tabela Resumo do Paciente B
resumo_B_final <- data.frame(
  Escopo = "Global (N=120) - Paciente B",
  Modelo = c("Elastic Net", "Random Forest", "ctree", "IA Universal (A->B)"),
  R2 = c(enet_metrics_B$Rsquared, rf_metrics_B$Rsquared, r2_ctree_B, 0.301),
  MAE = c(enet_metrics_B$MAE, rf_metrics_B$MAE, mae_ctree_B, NA) # MAE da generalização depende de escala
)

knitr::kable(resumo_B_final, digits = 3, caption = "Performance dos Modelos - Paciente B")

```

Table 3: Performance dos Modelos - Paciente B

Escopo	Modelo	R2	MAE
Global (N=120) - Paciente B	Elastic Net	0.650	1.080
Global (N=120) - Paciente B	Random Forest	0.677	0.974
Global (N=120) - Paciente B	ctree	0.493	1.064
Global (N=120) - Paciente B	IA Universal (A->B)	0.301	NA

Ao testar a generalização do modelo (IA treinada no Paciente A prevendo o Paciente B), observou-se uma queda no R2 para 0,40. Este achado é o pilar central desta proposta à FAPEMIG: ele evidencia que patologias motoras complexas (Esclerose Tuberosa) exigem a Multimodalidade. A IA atual, baseada diversos sinais de em áudio, incluindo o ruído, possui um “ponto cego” para interações puramente gestuais. O suporte financeiro solicitado permitirá a integração de Visão Computacional (Pose Estimation) e o uso de transdutores como o Musical-beam-05, visando elevar a precisão da generalização para patologias motoras ao patamar de R2 > 0,80.

4 Modelo Unificado (A + B)

Só com features MIR

```

# 1.1 Preparar Paciente A
df_A_full <- df_psicoA %>%
  mutate(video_num = Videos, target_z = as.numeric(scale(INTER_A_WEIGHTED)), Paciente = "A") %>%
  inner_join(df_acoustic %>% mutate(video_num = as.numeric(str_extract(file, "[0-9]+"))), by = "video_num")
  select(video_num, target_z, Paciente, rms_mean:mfcc_12)

# 1.2 Preparar Paciente B
# Usando o df_psico_B que criamos com a lógica da EFA (NP+QR+IN - VO-MV)
df_B_full <- df_psico_B %>%
  mutate(video_num = Videos, target_z = as.numeric(scale(INTER_B)), Paciente = "B") %>%

```

```

    inner_join(df_acousticB %>% mutate(video_num = as.numeric(str_extract(file, "[0-9]+"))), by = "video_num",
    select(video_num, target_z, Paciente, rms_mean:mfcc_12)

# 1.3 Unificar Psico-Acústico
df_psico_acust_uni <- rbind(df_A_full, df_B_full)

# 2.1 Padronizar MERT (Garantir que os nomes de arquivos casem com video_num)
df_mert_uni <- rbind(
  df_mert %>% mutate(video_num = as.numeric(str_extract(file, "[0-9]+")), Paciente = "A"),
  df_mertB %>% mutate(video_num = as.numeric(str_extract(file, "[0-9]+")), Paciente = "B")
)

# 2.2 O Grande Join Universal
df_universal_bruto <- df_mert_uni %>%
  inner_join(df_psico_acust_uni, by = c("video_num", "Paciente"))

# 2.3 PCA Global (Aprender o espaço sonoro unificado)
mert_cols_uni <- df_universal_bruto %>% select(starts_with("mert_"))
nzv_uni <- nearZeroVar(mert_cols_uni)
if(length(nzv_uni) > 0) mert_cols_uni <- mert_cols_uni[, -nzv_uni]

pca_uni <- prcomp(mert_cols_uni, scale. = TRUE)
n_pcs_uni <- which(cumsum(pca_uni$sdev^2) / sum(pca_uni$sdev^2) >= 0.95)[1]

mert_red_uni <- as.data.frame(pca_uni$x[, 1:n_pcs_uni])
colnames(mert_red_uni) <- paste0("PC_UNI_", 1:n_pcs_uni)

# 2.4 Dataset Final para ML
df_final_universal <- cbind(
  mert_red_uni,
  df_universal_bruto %>% select(rms_mean:mfcc_12, target_z, Paciente)
)

```

4.1 Random Forest

```

# 1. Selecionar apenas as features MIR (Librosa) e o alvo INTER
df_A_mir_only <- df_total %>%
  select(rms_mean:mfcc_12, INTER)

# 2. Treinar o modelo Elastic Net Minimalista
set.seed(456)
train_ctrl_mir <- trainControl(method = "repeatedcv", number = 10, repeats = 5)

model_A_mir <- train(
  INTER ~ .,
  data = df_A_mir_only,
  method = "glmnet",
  trControl = train_ctrl_mir,
  tuneLength = 10,
  metric = "Rsquared"
)

```

```

)

# 3. Ver os resultados do treinamento
#print(model_A_mir)

# 4. Comparativo Estratégico de Sócio
r2_com_mert <- 0.827
r2_apenas_mir <- max(model_A_mir$results$Rsquared)

cat("\n--- RESULTADO DO DESAFIO: IA PROFUNDA VS. MIR SIMPLES ---\n")

##
## --- RESULTADO DO DESAFIO: IA PROFUNDA VS. MIR SIMPLES ---

cat("R2 com MERT (Estrutura Musical):", r2_com_mert, "\n")

## R2 com MERT (Estrutura Musical): 0.827

cat("R2 apenas MIR (Energia/Timbre):", round(r2_apenas_mir, 3), "\n")

## R2 apenas MIR (Energia/Timbre): 0.698


cat("Diferença de Sinal (Explicação Perdida):", round(r2_com_mert - r2_apenas_mir, 3), "\n")

## Diferença de Sinal (Explicação Perdida): 0.129

# 5. Visualizar a importância das variáveis MIR no Paciente A
plot(varImp(model_A_mir), top = 10, main = "Top 10 MIR - O que a física do som explica no Paciente A?")

```

Top 10 MIR - O que a física do som explica no Paciente A?



4.2 Teste Final - Elastic Net “portátil”

```
features_mir <- c("rms_mean", "rms_std", "zcr_mean", "spectral_centroid",  
                  "spectral_flatness", "tempo_bpm", "onset_strength",  
                  paste0("mfcc_", 0:12))  
  
# 2. Treinar o modelo no Paciente A usando APENAS as features MIR  
set.seed(888)  
df_treino_A_mir <- df_total %>% select(all_of(features_mir), INTER)  
  
model_A_mir_portatil <- train(  
  INTER ~ .,  
  data = df_treino_A_mir,  
  method = "glmnet",  
  trControl = trainControl(method="cv", number=10)  
)  
  
# 3. Aplicar esse modelo nos dados do Paciente B  
df_teste_B_mir <- df_total_B %>%  
  select(all_of(features_mir), INTER = INTER_B)  
  
df_teste_B_mir$predito <- predict(model_A_mir_portatil, newdata = df_teste_B_mir)  
  
# 4. Calcular o R2 de Generalização
```

```
r2_gen_mir <- cor(df_teste_B_mir$INTER, df_teste_B_mir$predito, method = "spearman")^2
cat("--- RESULTADO DA GENERALIZAÇÃO MINIMALISTA ---\n")
```

```
## --- RESULTADO DA GENERALIZAÇÃO MINIMALISTA ---
```


```
cat("R2 da IA (A -> B) usando apenas MIR:", round(r2_gen_mir, 3), "\n")
```

```
## R2 da IA (A -> B) usando apenas MIR: 0.435
```

```
# 5. Plot de Dispersão da Generalização
ggplot(df_teste_B_mir, aes(x = INTER, y = predito)) +
  geom_point(color = "#27ae60", alpha = 0.6) +
  geom_abline(intercept = 0, slope = 1, linetype = "dashed", color = "red") +
  labs(title = "IA Minimalista: Treinada no A, Prevendo o B",
       subtitle = paste("R2 de Generalização MIR-only:", round(r2_gen_mir, 3)),
       x = "Escore Real Paciente B (NMT)",
       y = "Escore Predito pela IA do Paciente A (NR)") +
  theme_ipsum()
```

IA Minimalista: Treinada no A, Prevendo o B

R2 de Generalização MIR-only: 0.435



```
sessionInfo()
```

```
## R version 4.5.0 (2025-04-11 ucrt)
## Platform: x86_64-w64-mingw32/x64
```



```

## Running under: Windows 11 x64 (build 26200)
##
## Matrix products: default
##   LAPACK version 3.12.1
##
## locale:
## [1] LC_COLLATE=Portuguese_Brazil.utf8  LC_CTYPE=Portuguese_Brazil.utf8
## [3] LC_MONETARY=Portuguese_Brazil.utf8 LC_NUMERIC=C
## [5] LC_TIME=Portuguese_Brazil.utf8
##
## time zone: America/Sao_Paulo
## tzcode source: internal
##
## attached base packages:
## [1] stats4      grid      stats      graphics  grDevices  utils      datasets
## [8] methods     base
##
## other attached packages:
## [1] showtext_0.9-7      showtextdb_3.0      sysfonts_0.8.9
## [4] psych_2.5.3         boot_1.3-32         randomForest_4.7-1.2
## [7] party_1.3-18        strucchange_1.5-4   sandwich_3.1-1
## [10] zoo_1.8-14          modeltools_0.2-24   mvtnorm_1.3-3
## [13] glmnet_4.1-8        Matrix_1.7-3        caret_7.0-1
## [16] lattice_0.22-7      hrbrthemes_0.8.7    plotly_4.11.0
## [19] semTools_0.5-7      lavaan_0.6-20       readxl_1.4.5
## [22] lubridate_1.9.4     forcats_1.0.1       stringr_1.6.0
## [25] dplyr_1.1.4         purrr_1.2.1         readr_2.1.6
## [28] tidyr_1.3.1         tibble_3.3.1        ggplot2_4.0.2
## [31] tidyverse_2.0.0
##
## loaded via a namespace (and not attached):
## [1] libcoin_1.0-10      RColorBrewer_1.1-3  rstudioapi_0.17.1
## [4] jsonlite_2.0.0      shape_1.4.6.1       magrittr_2.0.4
## [7] TH.data_1.1-5       estimability_1.5.1  farver_2.1.2
## [10] rmarkdown_2.30      vctr_0.6.5          webshot_0.5.5
## [13] htmltools_0.5.8.1   cellranger_1.1.0    pROC_1.19.0.1
## [16] parallelly_1.44.0   htmlwidgets_1.6.4   plyr_1.8.9
## [19] emmeans_2.0.0       lifecycle_1.0.5     iterators_1.0.14
## [22] pkgconfig_2.0.3     webshot2_0.1.2      R6_2.6.1
## [25] fastmap_1.2.0       future_1.68.0       digest_0.6.38
## [28] ps_1.9.1            crosstalk_1.2.2     labeling_0.4.3
## [31] timechange_0.3.0    mgcv_1.9-4          httr_1.4.7
## [34] compiler_4.5.0      bit64_4.6.0-1       fontquiver_0.2.1
## [37] withr_3.0.2         S7_0.2.1            Rttf2pt1_1.3.14
## [40] MASS_7.3-65         lava_1.8.2          ModelMetrics_1.2.2.2
## [43] tools_4.5.0         chromote_0.5.1       pbivnorm_0.6.0
## [46] extrafontdb_1.1     future.apply_1.20.0  nnet_7.3-20
## [49] glue_1.8.0          quadprog_1.5-8       promises_1.3.2
## [52] nlme_3.1-168        reshape2_1.4.5       generics_0.1.4
## [55] recipes_1.3.1       gtable_0.3.6        tzdb_0.5.0
## [58] class_7.3-23        websocket_1.4.4      data.table_1.17.0
## [61] hms_1.1.4           coin_1.4-3           foreach_1.5.2
## [64] pillar_1.11.1       vroom_1.6.6         later_1.4.2
## [67] splines_4.5.0       survival_3.8-3       bit_4.6.0

```

##	[70]	tidyselect_1.2.1	fontLiberation_0.1.0	knitr_1.50
##	[73]	fontBitstreamVera_0.1.1	xfun_0.52	hardhat_1.4.2
##	[76]	timeDate_4051.111	matrixStats_1.5.0	stringi_1.8.7
##	[79]	lazyeval_0.2.2	yaml_2.3.10	evaluate_1.0.5
##	[82]	codetools_0.2-20	extrafont_0.20	gdtools_0.4.4
##	[85]	cli_3.6.5	rpart_4.1.24	xtable_1.8-4
##	[88]	systemfonts_1.3.1	processx_3.8.6	Rcpp_1.1.0
##	[91]	globals_0.18.0	coda_0.19-4.1	parallel_4.5.0
##	[94]	gower_1.0.2	listenv_0.10.0	viridisLite_0.4.3
##	[97]	ipred_0.9-15	scales_1.4.0	prodlim_2025.04.28
##	[100]	crayon_1.5.3	rlang_1.1.6	multcomp_1.4-29
##	[103]	mnormt_2.1.1		